

模式识别大作业

16231235 李谨杰

题目：一枚硬币，掷了一百次都是正面朝上，请问再掷一次正面朝上的概率是多少？

一、 问题分析

这个问题实际上是估计一个二项分布事件的发生的概率 p ，是一个参数估计问题。

首先说一种错误的解答：我们小学初中都学过，对于理想的硬币模型，扔出正面和反面的概率均为 0.5。而每次掷硬币均为独立实验，即使前面都是正面朝上，那么再掷一次正面朝上的概率还是 0.5，因此很多人认为这个问题的答案是 0.5。犯这样的错误的原因在于：用理想模型估计问题概率，没有考虑实际情况。

事实上，扔一百次硬币全部朝上的概率为 $\frac{1}{2^{100}} \approx 7.88 \times 10^{-31}$ ，是一个几乎不可能发生的概率极小的小概率事件。因此，我们有充足的理由相信，硬币掷出正反两面的概率是不相等的。

因而这个问题被转换为，由 100 个实验样本估计掷一次硬币正面朝上的概率。我们不妨根据经验做出如下假设：每一次掷硬币事件相互之间都是独立的，且扔出正面的概率 p 保持不变。由概率论中所讲的二项分布概率模型可知，前一百次实验出现正面次数 X 发生 n 次的概率为：

$$P(X = n) = C_{100}^n p^n (1 - p)^{100-n}$$

之后的问题即为根据样本数据估计该概率模型的参数 p 。

参数估计分为点估计和区间估计，概率论上曾讲过区间估计与点估计中矩估计的内容，这里不再赘述。我们书上主要介绍的是点估计中的最大似然估计（MLE）与贝叶斯估计，老师还讲了最大后验估计（MAP），本文将采用这三种模型分别对参数 p 进行估计。

二、 最大似然估计（MLE）

2.1 基本思想

基于已有的样本 X ，构造似然函数（likelihood function），找到一个 p 值，使得似然函数 $L(p|X)$ 达到最大，得到的 p 值即为最有可能的估计值。

2.2 具体求解

在本实验中， $X=100$ 出现的概率最大，则 p 的选取应使得该实验结果出现的概率达到最大。据此构造似然函数为：

$$L(p|X) = P(X = 100) = p^{100}$$

由于 $L(p)$ 是一个单增函数，故当 $p=1$ 时 $L(p)$ 最大。因此，由 MLE 出的正面朝上的概率为 1，即再掷一次正面朝上的概率为 1。

三、 最大后验估计（MAP）

3.1 基本思想

最大后验估计的思想也是构造后验概率函数，使得后验概率取极值。与最大似然估计相比，不同点在于 MAP 在估计未知量 θ 的函数中加入了先验概率 $p(\theta)$ ，其中先验概率指的是

人们已经知道或普遍接受的规律。后验估计来自于贝叶斯公式：

$$p(\theta | X) = \frac{p(X | \theta) \cdot p(\theta)}{p(X)}$$

$$\text{posterior} = \frac{\text{likelihood} \cdot \text{prior}}{\text{evidence}}$$

因为公式中分母 $p(X)$ 与 θ 无关，该估计等价于选取 θ 使分子最大，即

$$\hat{\theta}_{MAP} = \operatorname{argmax}_{\theta} \frac{p(X | \theta) p(\theta)}{p(X)}$$

$$= \operatorname{argmax}_{\theta} p(X | \theta) p(\theta)$$

3.2 具体求解

在本实验中，对硬币的经验告诉我们，扔硬币正面朝上的次数满足二项分布，且满足先验概率在 $\theta = 0.5$ 时取得最大值，因此可以选用二项分布的共轭先验分布函数 B 分布：

$$p(\theta) = p(p | \alpha, \beta) = \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1} = \text{Beta}(p | \alpha, \beta)$$

其中 $Beta$ 函数展开式为：

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha + \beta)}$$

当 X 为正整数时， $\Gamma(n) = (n-1)!$ 。

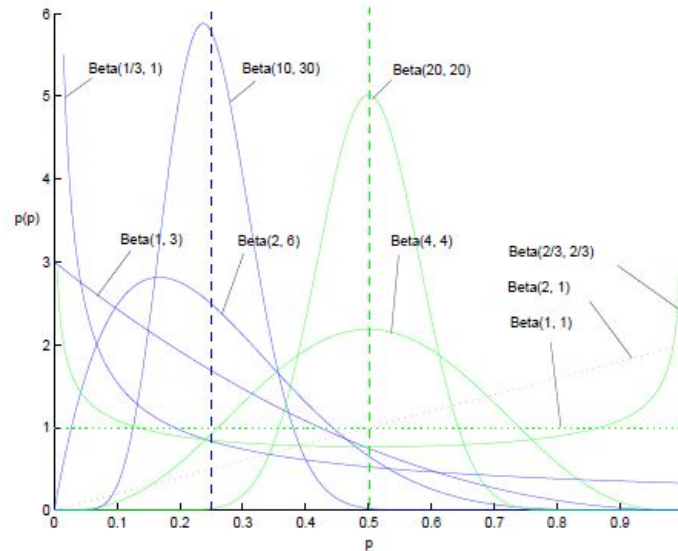


图 3.1 不同 α ， β 值时 $Beta$ 分布的概率密度函数

图 3.1 为不同 α ， β 值时 $Beta$ 分布的概率密度函数。如图可知，若在 $\theta = 0.5$ 时取得最大值，需要 $\alpha = \beta$ 。

由 $p(\theta)$ 与 $\hat{\theta}_{MAP}$ 的定义，构造的 MAP 函数为

$$\hat{\theta}_{MAP} = p^{100} \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}$$


下面对该式求导：

$$\frac{\partial \hat{\theta}_{MAP}}{\partial p} = (\alpha + 99)(1-p) + p(1-\beta) = 0$$

解得：

$$p = \frac{\alpha + 99}{\alpha + \beta + 98}$$

由上文可知， $\alpha = \beta$ ， α 取值与得到正面概率 p 的关系作图如下：



从后验估计的思想可知，对参数的估计加入了先验概率。造币水平越高，我们认为 p 参数在 0.5 附近的可能性越大，因而最终对下一次掷出正面的估计概率就越小，符合上图的变化趋势。

若认为造币工艺较差，取 $\alpha = \beta = 4$ ，则下一次掷出正面的概率为 $p=0.9716$ ；若认为造币工艺较好，取 $\alpha = \beta = 20$ ，则下一次掷出正面的概率为 $p=0.8623$ 。可以看到 α 相当于将结果“拉”向先验概率的幅度， α 越大，顶峰越尖锐，概率越集中。

四、 贝叶斯估计：

4.1 基本概念

贝叶斯估计和极大后验估计思想较为类似，均希望后验概率达到最大，但贝叶斯估计不具体估计参数的值，而是允许参数服从一定的概率分布，以整体的损失最小来估计参数。同时贝叶斯估计在估计后验概率时，不能忽略分母 $p(X)$ 。

回顾一下贝叶斯公式和全概率公式：

$$p(\theta | X) = \frac{p(X | \theta) \cdot p(\theta)}{p(X)}$$

$$p(X) = \int_{\theta \in \Theta} p(X | \theta) p(\theta) d\theta$$

由模式识别教材，贝叶斯估计的步骤为：

1. 根据对问题的认识确定 θ 的先验分布密度 $p(\theta)$
2. 由于样本独立同分布，而且已知样本密度函数的形式 $p(x|\theta)$ ，可以形式上求出样本集的联合分布如下，其中 θ 为变量。

$$p(x | \theta) = \prod_{i=1}^N p(x_i | \theta)$$

3. 利用贝叶斯公式求 θ 的后验概率分布：

$$p(\theta | x) = \frac{p(x | \theta) p(\theta)}{\int_{\Theta} p(x | \theta) p(\theta) d\theta}$$

4. 若采用平方误差损失函数，则 θ 的估计量为

$$\theta^* = \int_{\Theta} \theta p(\theta | x) d\theta$$

4.2 具体求解

在这一小节中，为了避免混淆待估计参数 p 与概率符号 p ，我将以 θ 代替待估计参数 p 。

在本实验中，类似最大后验估计，我们假设先验分布为 B 分布。但构造贝叶斯估计时，不是采用使后验概率最大时的参数 θ 作为参数值，而是以满足 B 分布的 θ 的期望，即：

$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta$$

来作为 p 的参数估计值。

参数 θ 满足的概率分布为：

$$\begin{aligned} p(\theta | C, \alpha, \beta) &= \frac{\prod_{i=1}^N p(C = c_i | \theta) p(\theta | \alpha, \beta)}{\int_0^1 \prod_{i=1}^N p(C = c_i | \theta) p(\theta | \alpha, \beta) d\theta} \\ &= \frac{p^{n^{(1)}} (1-p)^{n^{(0)}} \frac{1}{B(\alpha, \beta)} p^{\alpha-1} (1-p)^{\beta-1}}{Z} \\ &= \text{Beta}(\theta | n^{(1)} + \alpha, n^{(0)} + \beta) \end{aligned}$$

这里用到了公式

$$\int_p \prod_{t=1}^{|T|} P_t^{\alpha_t-1} = B(\alpha)$$


由该结果可知，根据贝叶斯估计，参数 θ 满足一个新的 B 分布，与先验分布形式相同，因此称二项分布与 $Beta$ 分布是共轭分布。根据 B 分布的期望，我们有：

$$\theta^* = \frac{n^{(1)} + \alpha}{n^{(1)} + n^{(0)} + \alpha + \beta} = \frac{100 + \alpha}{100 + \alpha + \beta}$$

若认为造币工艺较差，取 $\alpha = \beta = 4$ ，则下一次掷出正面的概率为 $p=0.9629$ ；若认为造币工

艺较好，取 $\alpha = \beta = 20$ ，则下一次掷出正面的概率为 $p=0.8571$ 。

贝叶斯估计与最大后验概率估计的 α 选值与得到正面概率 p 的关系作图如下：



可以看到相同先验概率分布的条件下，贝叶斯估计得出的概率稍低于最大后验概率，但整体上相差不大。这说明针对这个问题，最大后验分布与贝叶斯估计的结果类似。

五、 结论

本文通过最大似然估计、最大后验估计和贝叶斯估计这三种方法，对下一次掷硬币出现正面的概率进行预估，结果分别为 1, 0.9716 和 0.9629 ($\alpha = 4$)。因此，这是一枚严重有问题的硬币。

根据贝叶斯估计的原理，也可以随着样本数据实时调整估计量，即贝叶斯学习。当观测到新的数据时，可以通过这个数据调整后验概率，公式如下：

$$p(\theta | X^N) = \frac{p(x_N | \theta) p(\theta | x^{N-1})}{\int_{\Theta} p(x_N | \theta) p(\theta | x^{N-1}) d\theta}$$

$$\theta^* = E[\theta | x] = \int_{\Theta} \theta p(\theta | x) d\theta$$

根据这一百个实验数据，按上述公式迭代一百次得到的概率与贝叶斯估计应该相同。但我用 matlab 编写上述程序时总是报错，可能是对连续变量的操作有些问题，目前还没有实现。

通过这个小例子，我还有两个感悟：1. 小概率事件发生意味着有什么地方出错了 2. 对生活中的概率问题一定要科学分析。

参考文献

1. 何书元. *概率论与数理统计*. 高等教育出版社, 2006.
2. 张学工编著. *模式识别 (第三版)*. 清华大学出版社, 2010.
3. 三种参数估计方法 (MLE, MAP, 贝叶斯估计)
https://blog.csdn.net/leo_xu06/article/details/51222215
4. 知乎问答 <https://www.zhihu.com/question/29683794>